●行ったタスク
・名前：スポーツ予測に関する2値分類タスク
・概要：選手データからドラフト指名の有無を予測

●工夫した点

1. データの可視化(EDA)
　与えられた特徴量を可視化する事で、それぞれのデータの関係性や特徴量エンジニアリングの糸口を探った。「欠損値があるカラムは特別な意味があるのではないか？」「目的変数と関係がありそうな特徴量はどこか？」などを考える手がかりになった。

2. ドメイン知識の調査
　コンペの題材自体の知識獲得に励んだ。データ分析における前提知識が増えたことで、本コンペティションのデータセットにおける特徴量の意味(「ある特徴量の分布が二つの山の形状になっているのは、ある特徴量の特性が2文されているからだ」など)や特徴量エンジニアリングするための知見増加につながった。

3. 特徴量エンジニアリング
　様々な特徴量エンジニアリングを実践したが効果があったのは下記の特徴量エンジニアリングだった。

    a. データの前処理
    　カテゴリカルデータのままではAIモデルを実行できないのでエンコーディングを施した。Xgboostは欠損値があっても実行できるモデルであり、欠損値があった方が良い精度だったのでそのままにした。

    b. 不要な特徴量の削除
    　ある特徴は各選手の状態を示す上で一見重要だったが、そのまま活用しても精度向上に寄与しなかったため、削除した。

    c. 複数の特徴量から、一般に知られている別の特徴量を作成
    　複数の特徴量から一般に知られている別の特徴量を2つ作成した。
    　1つめは、2つの特徴量から一般に知られている別の特徴量を作成することが可能で、その特徴量を加えると精度が向上した。
    　2つめは、ドメイン調査で得られた既存の特徴量から生成した複数の特徴量を用いて生成できる特徴量に対して、各構成要素を明示的に加えた方が精度向上に寄与したため、各構成要素を明示的に追加した。

    d. 欠損値を明示的にフラグ化
    　ある特徴量が欠損している選手はそれを公表したくない後ろ向きな理由があり、それが分類精度に影響を及ぼし得ると考え、ある特徴量が欠如しているというフラグを明示的に作成した。

4. モデルの選定
　ベースラインはバギング手法である”Random Forester”を用いていたが、間違いを逐次的に修正する勾配ブースティングを有する”Xgboost”の方が強力であると判断し、そちらを採用した。

5. ハイパーパラメータのチューニング
　Xgboostは”learning_rate”や”max_depth”など多くのハイパーパラメータを有しており、optunaによって検証した。最後の仕上げとして何通りも試し、精度向上に寄与することができた。

6. 学習時の工夫
　early stoppingといった正則化を加えて過学習を抑制した。またk-folod交差検証によって検証lossの平均を出力することで、精度の高いチューニングを実現した。

7. 特徴重要度の可視化
　特徴重要度に対するCV(変動係数。std/meanによって定義される、各foldにおける特徴量の特徴重要度のばらつき)を計算した。CVが小さい特徴量ほど各foldごとに重要と判断されている特徴量である。
　更に各foldにおける特徴重要度の平均が大きい順に可視化した。特徴量重要度の平均が大きく、CVが小さい(ばらつきが小さい)特徴量が重要な特徴量であり、特徴量エンジニアリングで加えた特徴量が良い特徴量か判断する際の指標に用いた。

●結果:
　これらの工夫を加えることでAUCスコアをベースライン(0.80792)から**0.84705**まで改善することができた。

●順位:上位3.1%

●感想:
　本コンペティションのデータがテーブルデータであるからこそ、事前学習済みモデルの活用ではなく特徴量エンジニアリングが大切であり、そのためにデータをしっかり分析することが重要だった。EDAを通じたデータ分析とドメイン知識の調査を背景に特徴量エンジニアリングを行うことは非常に難しかったが、AIモデル作成の基礎である「**データを利活用する視点**」を養えたと感じている。この視点は最終課題におけるAI分析技術を用いたビジネス提案において大いに役立った。
　またデータ分析における学習モデルの使い方やデータの可視化といった**データ分析における基礎を獲得することもできた。**
　本課題が初めての本格的なAIコンペティションだったが様々な知識を体系的に獲得することができた。これらの知識・経験を今後のモデル開発やデータ分析につなげていきたい。