**●行ったタスク**
・名前：NFL Draft Prediction
・概要：ナショナル・フットボール・リーグ（NFL）の選手に関する身体能力テストやポジション情報などのデータをもとに、その選手がドラフトで指名されるかどうか（Draftedか否か）を予測する分類モデルの構築を目指す
・データについて

| 変数 | 定義 |
|---|---|
| Id | 選手ごとの一意のID |
| Year | データの対象となる年 |
| Age | 年齢 |
| School | 所属学校名 |
| Height | 身長 (m) |
| Weight | 体重 (kg) |
| Sprint_40yd | 40ヤード走のタイム(s)(40ヤード走（40-yard dash）とは、アメリカンフットボールの選手が持つスピード及び加速力を40ヤード（36.58m）走ることで評価する指標の一つであり、NFLスカウティングコンバインのテスト項目である。) |
| Vertical_Jump | 垂直跳びの到達点 (cm) |
| Bench_Press_Reps | ベンチプレスの回数 (回) |
| Broad_Jump | 立ち幅跳びの距離 (cm) |
| Agility_3cone | 3コーンドリルのタイム(s) |
| Shuttle | 20ヤードシャトルランのタイム(s)(スタート > 5ヤード走る > 右手でタッチ > 10ヤード走る > 左手でタッチ > 5ヤード走る >終わり) |
| Player_Type | 大まかな役割の分類 |
| Position_Type | ポジションのタイプ |
| Position | 詳細なポジション |
| Drafted | ドラフトされたかどうか |

**●工夫した点**

1. データの可視化(EDA)
　与えられた特徴量を可視化する事で、それぞれのデータの関係性や特徴量エンジニアリングの糸口を探った。「欠損値があるカラムは特別な意味があるのではないか？」「目的変数と関係がありそうな特徴量はどこか？」などを考える手がかりになった。

2. ドメイン知識の調査
　コンペの題材自体の知識獲得に励んだ。データ分析における前提知識が増えたことで、本コンペティションのデータセットにおける特徴量の意味(「体重の分布が二つの山の形状になっているのは、”ライン”と”スキルポジション”という”フォワード”と”バックス”のような2つのくくりかあるからだ」など)や特徴量エンジニアリングするための知見増加につながった。

3. 特徴量エンジニアリング
　様々な特徴量エンジニアリングを実践したが効果があったのは下記の特徴量エンジニアリングだった。

    a. データの前処理
    　カテゴリカルデータのままではAIモデルを実行できないのでエンコーディングを施した。Xgboostは欠損値があっても実行できるモデルであり、欠損値があった方が良い精度だったのでそのままにした。

    b. 不要な特徴量の削除
    　”School”の特徴は各選手の出身校という強力な特徴であるが、そのまま活用しても精度向上に寄与しなかったため、削除した。

    c. BMI

”Height”と”Weight”から作成した”BMI”の特徴量がモデルの精度向上につながった。

d. ASIの各要素を明示的に追加
ドメイン知識の調査やSlackでの共有により、ASI「Athletic Success Indicator（運動能力成功指標）」というNFLコンバイン（入団前テスト）やプロデーの測定値をもとにドラフト候補選手のNFLでの成功を予測するための指標が存在することが分かった。
ASIは”垂直跳びを体重で調整した値”や”幅跳びを体重で調整した値”などから構成されており、ASIそのものよりも構成要素を明示的に加えた方が精度向上に寄与したため、各構成要素を明示的に追加した。

e. Age_missing
”Age”が欠損している選手は年齢を公表したくない後ろ向きな理由があると考え、年齢が欠如しているというフラグを明示的に作成した。

4. モデルの選定
ベースラインはバギング手法である”Random Forester”を用いていたが、間違いを逐次的に修正する勾配ブースティングを有する”Xgboost”の方が強力であると判断し、そちらを採用した。

5. ハイパーパラメータのチューニング
Xgboostは”learning_rate”や”max_depth”など多くのハイパーパラメータを有しており、optunaによって検証した。最後の仕上げとして何通りも試し、精度向上に寄与することができた。

6. 学習時の工夫
early stoppingといった正則化を加えて過学習を抑制した。またk-folod交差検証によって検証lossの平均を出力することで、精度の高いチューニングを実現した。

7. 特徴重要度の可視化
特徴重要度に対するCV(変動係数。std/meanによって定義される、各foldにおける特徴量の特徴重要度のばらつき)を計算した。CVが小さい特徴量ほど各foldごとに重要と判断されている特徴量である。
更に各foldにおける特徴重要度の平均が大きい順に可視化した。特徴量重要度の平均が大きく、CVが小さい(ばらつきが小さい)特徴量が重要な特徴量であり、特徴量エンジニアリングで加えた特徴量が良い特徴量か判断する際の指標に用いた。

**●結果:**
これらの工夫を加えることでAUCスコアをベースライン(0.80792)から**0.84705**まで改善することができた。

●**順位:**107位/3434人中

●**感想:**

本コンペティションのデータがテーブルデータであるからこそ、事前学習済みモデルの活用ではなく特徴量エンジニアリングが大切であり、そのためにデータをしっかり分析することが重要だった。EDAを通じたデータ分析とドメイン知識の調査を背景に特徴量エンジニアリングを行うことは非常に難しかったが、AIモデル作成の基礎である「**データを利活用する視点**」を養えたと感じている。この視点は最終課題におけるAI分析技術を用いたビジネス提案において大いに役立った。

またデータ分析における学習モデルの使い方やデータの可視化といった**データ分析における基礎を獲得することもできた。**

本課題が初めての本格的なAIコンペティションだったが様々な知識を体系的に獲得することができた。これらの知識・経験を今後のモデル開発やデータ分析につなげていきたい。